

DATA SCIENCE

BIG DATA ARCHITECTURING & DATA INTEGRATION Prof. Dr. Renê de Ávila Mendes

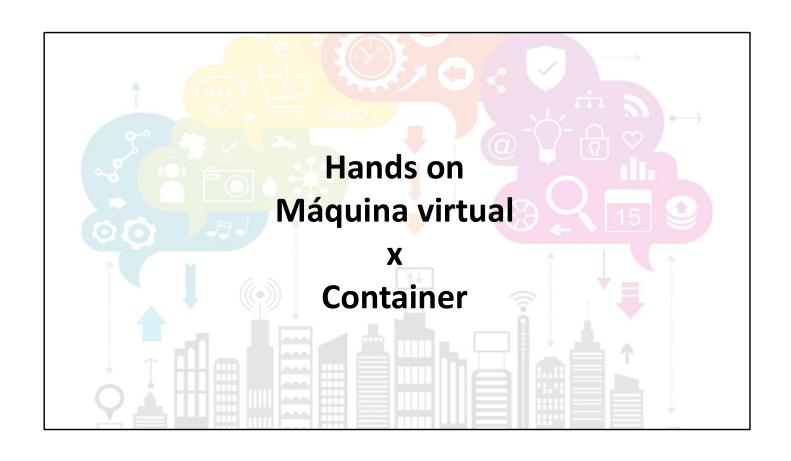
Objetivos da disciplina

DISCIPLINA: Big Data Architecturing & Data Integration

OBJETIVOS: Entenda as principais arquiteturas para ingestão, processamento e análise de grandes volumes de dados. Conheça as principais ferramentas open-source de Big Data como Hadoop, MapReduce, Spark, Sqoop, NiFi, Flume, Kafka, Zookeeper, HBase, Hive e as integre com as ferramentas de extração, transformação e carga de dados em modelos dimensionais. Entenda conceitos sobre computação paralela e distribuída, aplicação do Hadoop e bases Apache e arquiteturas serverless e desacopladas. Veja como visualizar os dados estruturados ou não estruturados com ferramentas de Self-Service Business Intelligence como PowerBI, utilizando as melhores práticas de visualização de dados.

Assuntos – 1º Semestre

- Introdução a Big Data
- Conceitos Computação Paralela e Distribuída, Lei de Moore, Sistema HDFS
- Aplicação Hadoop. Usos e Administração de Ambientes Hadoop
- Introdução a MapReduce
- Introdução à Integração de Dados
- Integração entre SQL e Hadoop SQOOP
- Bases Apache
- Bases Apache PIG
- Introdução da Data Streaming FLUME
- Introdução a análise de dados com SPARK



VM Hadoop

• Alterar a configuração do local:

Arquivo > Preferências > Pasta padrão para máquinas: "D:\"

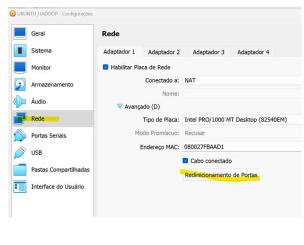
- Importar a imagem
- Usuário e senha
 - hadoop / hadoop



VM Hadoop

- Mapear portas
 - -SSH





 $FI \land P$

Linux - Comandos

- ls lista o diretório
 - Is
 - Is > teste.txt
- cat lista o conteúdo de um arquivo
 - cat teste.txt
- mkdir cria diretório
 - mkdir teste

- 8

 $FI \land P$

Linux - Comandos

- cp copia arquivo
 - cp teste.txt teste1.txt
- mv move um arquivo
 - mv teste1.txt /etc/teste2.txt
- rm apaga arquivo
 - rm /etc/teste2.txt

FIAP

Comandos frequentemente usados

- Comandos shell são usados para executar várias operações Hadoop HDFS e para gerenciar os arquivos presentes em clusters HDFS.
- Todos os comandos são invocados pelo script bin/hdfs ou bin/hadoop.
- version.
 - Imprime a versão do hadoop
 - hadoop version

Comandos frequentemente usados

- classpath.
 - Exibe o caminho das classes e bibliotecas do Hadoop. Definido no arquivo hadoop-config.sh.
 - hadoop classpath

11

http://namenode-name:50070/

 $FI \land P$

Comandos frequentemente usados

- getconf.
 - Exibe informações de configuração do diretório de configurações.
 - hdfs getconf -namenodes
 - hdfs getconf -secondaryNameNodes
 - hdfs getconf -backupNodes
 - hdfs getconf -includeFile
 - hdfs getconf -excludeFile
 - hdfs getconf -nnRpcAddresses

- -namenodes gets list of namenodes in the cluster.
- -secondaryNameNodes gets list of secondary namenodes in the cluster.
- -backupNodes gets list of backup nodes in the cluster.
- -includeFile gets the include file path that defines the datanodes that can join the cluster.
- -excludeFile gets the exclude file path that defines the datanodes that need to decommissioned.
- -nnRpcAddresses gets the namenode rpc addresses
- -confKey [key] gets a specific key from the configuration

Comandos frequentemente usados

- mkdir.
 - Cria um diretório no path informado.
 - hadoop dfs -mkdir testel-seunome
 - hadoop dfs -mkdir teste2-seunome
 - hadoop dfs -mkdir teste3-seunome

Comandos frequentemente usados

- ls.
 - Exibe uma lista do conteúdo de um diretório especificado no path.
 Pode exibir permissões, proprietário, tamanho e data de criação/alteração de cada arquivo.
 - hadoop dfs -ls
 - hadoop dfs -ls -R

Comandos frequentemente usados

- copyFromLocal.
 - Copia um arquivo ou diretório do file system local para o destino especificado no HDFS.
 - -hadoop dfs -copyFromLocal
 /usr/local/hadoop/etc/hadoop/*.xml testel seunome

 $\lceil | \land |
ceil$

Comandos frequentemente usados

- cat.
 - Exibe o conteúdo de um arquivo na console ou na **stdout**.
 - -hadoop dfs -cat testel-seunome/coresite.xml

Comandos frequentemente usados

- copyToLocal.
 - Copia um arquivo ou diretório do HDFS para o file system local.
 - -hadoop dfs -copyToLocal teste1seunome/core-site.xml .
 - -hadoop dfs -ls teste1-seunome

Comandos frequentemente usados

- cp
 - Copia um arquivo ou diretório de uma origem identificada no comando para um destino identificado no comando
 - -hadoop dfs -cp teste1-seunome/*.xml
 teste2-seunome

Comandos frequentemente usados

- mv
 - Move um arquivo ou diretório de uma origem identificada no comando para um destino identificado no comando
 - -hadoop dfs -mv teste1-seunome/coresite.xml teste3-seunome

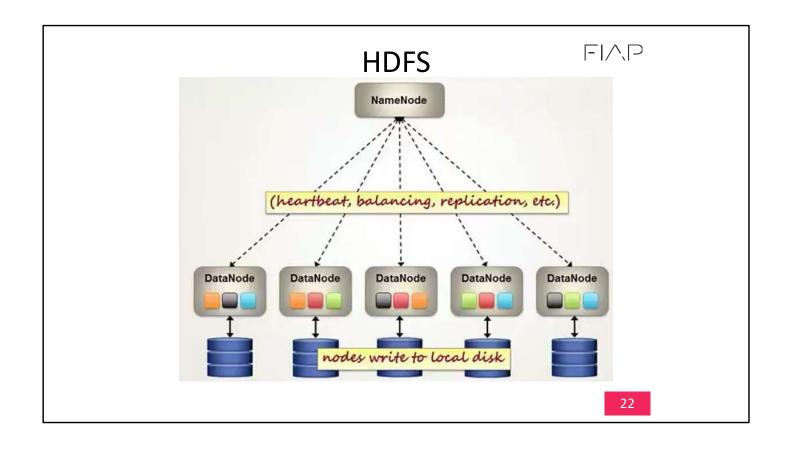
Comandos frequentemente usados

- chmod
 - Altera as permissões de leitura, gravação e execução de um arquivo
 - -hadoop dfs -chmod 777 teste2-seunome/*

	Owner	Group	Other
Read (r)	4	4	4
Write (w)	2	2	2
Execute (x)	1	1	1
Total	7	7	7

Comandos frequentemente usados

- rm
 - Apaga um arquivo ou diretório
 - -hadoop dfs -rm teste2-seunome/core-site.xml
 - -hadoop dfs -rm -r testel-seunome
 - -hadoop dfs -rm -r teste2-seunome
 - -hadoop dfs -rm -r teste3-seunome



Namespace

FI/VD

 "É um delimitador abstrato (container) que fornece um contexto para os itens que ele armazena (nomes, termos técnicos, conceitos), o que permite uma desambiguação para itens que possuem o mesmo nome mas que residem em espaços de nomes diferentes. Como um contexto distinto é fornecido para cada container, o significado de um nome pode variar de acordo com o espaço de nomes o qual ele pertence" (O'Reilly Strata, 2015)

 $FI \land P$

- Conhecido do como nó mestre (master node)
- É o servidor que armazena os metadados da árvore de diretório, réplicas, número de bloco de dados e outros detalhes
- Os metadados estão disponíveis na memória para recuperação mais rápida dos dados.

 FI/\sqrt{P}

- Mantém e gerencia os nós escravos e atribui tarefas a eles.
- Normalmente implementado em hardware confiável pois é peça central do HDFS.

FIMP

```
cd $HADOOP_HOME/etc/hadoop/
ls -ltr
vi core-site.xml
```

• A property fs.defaultFS especifica a localização do namenode.

```
<name>fs.defaultFS</name>
  <value>hdfs://ip-172-31-45-216.ec2.internal:8020</value>
```

• Este arquivo fica disponível em todos o **nodes** do **cluster** permitindo que todos **nodes** saibam a localização do **namenode**.

Tarefas do NameNode

FIMP

- Gerencia o *namespace* do sistema de arquivos
- Regula o acesso do cliente aos arquivos
 - Não existe quota de usuário
- Executa operações do file system
 - nomeação, abertura e fechamento de arquivos ou diretórios.

Tarefas do NameNode

FIMP

- Todos os DataNodes enviam *Heartbeats* e *block reports* para o NameNode.
 - Heartbeats garantem que o nó está ativo
 - Block Report contém a lista de blocos do datanode
- Responsável por cuidar do Replicator Factor de todos os blocos.

Arquivos do NameNode

FIMP

- Arquivos presentes nos metadados do NameNode:
- FsImage
 - É um "arquivo de imagem".
 - Contém o namespace inteiro do sistema de arquivos
 - Armazenado como um arquivo no file system no namenode
 - Contém uma forma serializada de todos os diretórios e arquivos *inode* do sistema
 - Inode é uma representação interna dos metadados dos arquivos e diretórios.

EditLogs

- Contém todas as alterações recentes feitas no **FsImage** mais recente.
- Ao receber uma solicitação de criação, atualização ou exclusão do cliente, o Namenode primeiro registra essa solicitação no arquivo de edição.

Arquivos do NameNode Primary namenode Master Namenode Get/Read Initial information from fsimage and store in main memory Into logs Disk Storage metadados alterações

DataNode

FIMP

- Conhecido como Slave.
- Armazena dados reais no HDFS.
- Executa a operação de leitura e gravação de acordo com a solicitação do cliente.
- DataNodes podem ser implantados em hardware de commodities.

FIMP

cd etc/hadoop
ls -ltr
vi hdfs-site.xml

- **dfs.namenode.name.dir** especifica onde o **NameNode** pode armazenar seus arquivos, localmente.
- **dfs.datanode.name.dir** especifica onde o **DataNode** pode armazenar arquivos e blocos, localmente
- **dfs.namenode.http.address** fornece o endereço no **NameNode**. O endereço pode ser acessado através de um *browser* e fornecer informações sobre o HDFS.

Tarefas do DataNode

FIMP

- Bloquear a criação, exclusão e replicação conforme as instruções enviadas pelo **Namenode**.
- Gerenciar o armazenamento de dados do sistema.
- Enviar heartbeats para o NameNode
 - Por padrão, a freqüência é de 3 segundos.

Replicação

 $FI \land P$

- Replicação de blocos fornece tolerância a falhas.
- Se uma cópia não for acessível ou estiver corrompida, pode ser lida de outra cópia.
- O número de cópias ou réplicas de cada bloco de um arquivo é o fator de replicação (3, por padrão). Cada bloco e replicado três vezes e é armazenado em diferentes **DataNodes**.
- Em uma configuração padrão, um arquivo de 128 MB em HDFS ocupa 384 MB (3 * 128 MB) de espaço.
- NameNode recebe relatório de bloco do **DataNode** periodicamente para manter o fator de replicação.
- Se um bloco estiver super-replicado / sub-replicado, o **NameNode** adiciona ou exclui as réplicas conforme necessário.

Replicação

 $FI \land P$

- -hadoop dfs -ls teste3-seunome
- -hadoop dfs -Ddfs.replication=2 -cp teste2seunome/yarn-site.xml teste2-seunome/teste.xml
- -hadoop dfs -ls teste2-seunome
- -hadoop dfs -ls teste2-seunome/teste.xml

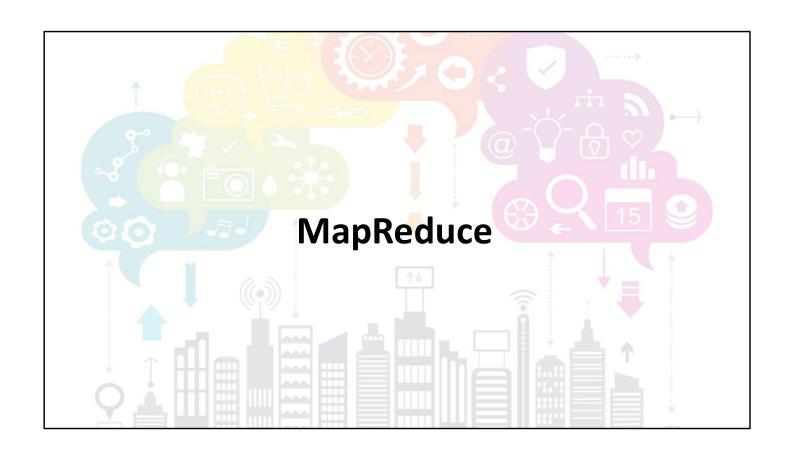


Checkpoint 1

Data: 27/03

Data de entrega: 02/04

Entrega: Portal do aluno



Map Reduce

MapReduce: Simplified Data Processing on Large Clusters

 Em 2004 o Google publicou o artigo chamado MapReduce: Simplified Data Processing on Large Clusters.

jeff@google.com Goog

MapReduce é um modelo de programação para processamento de grandes volumes de dados.

 Esta abstração foi inspirada nas primitivas map e reduce do Lisp e outras linguagens funcionais. Jeffrey Dean and Sanjay Ghemas jeff@google.com, sanjay@google.com Google, Inc.

MynReduce is a programming model and an associated implementation for processing and generalizing large data set. Users specify a may function that processes a keyvalue pair to generate set of intermediate keyvalue pairs, and a reduce function that merges all intermediate values associated with the sum intermediate key. Many real world tasks are expressible in this model, as shown in the paper.

Programs written in this functional style are automatically parallelized and executed on a large cluster of commodify machines. The run eline system takes care of the letalist of partitioning the input data, scheduling the programs is execution across a set of machines, handling machine failures, and managing the required inter-machine communication. This allows programmers without any apexperience with parallel and distributed systems to easiy utilize the resource of a large distributed systems.

Our implementation of MapReduce runs on a large cluster of commodity machines and is highly scaledies a typical MapReduce computation processes many terahytes of data on thousands of machines. Programmers find the system casy to use: hundreds of MapReduce programs have been implemented and upwards of one busand MapReduce jobs are executed on Google's clusters every day.

1 Introduction

Over the past five years, the authors and many others a Google have implemented hundreds of special-purpose computations that process large amounts of raw dains such as crawled documents, web request logs, etc., to compute various kinds of derived data, such as invertee indices, various representations of the gaph structure of web documents, summaries of the number of page crawled per host, the set of most frequent queries in given day, etc. Most such computations are enceptually straightforward. However, the input data is usually large and the computations have to be distributed across hardreds or thousands of machines in order to finish in a reasonable amount of time. The issues of flows to perallelize the computation, distribute the data, and handle failures conspire to obscure the original simple computation with large amounts of complex code to deal with

As a reaction to this complexity, we designed a new shareaction that disso us to express the simple computations we were trying to perform but hides the messy distalled of parallelization, faith softeness, and contribution and load balancing in a library. Our abstraction is inpared by the map and realizer primitives present in Lingtung and the contribution of the contribution of the most of our computations involved applying a map opmitted to each logical record? in our lipit in coder to compute a set of intermediate keylvalue pairs, and then applying a reader overgation to all the values that shared the same key, in order to combine the derived data appropriately. Our experiants to all the values of a functional most such such a propriately. The contribution of a functional most with userportation, the case of a functional most with userportation of the contribution of the contribution of the propriately. Our section of the contribution of the propriate of the contribution of the contribution of the propriate of the contribution of the propriate of the contribution of the contribution of the propriate of the contribution of the contribution of the propriate of the contribution of the contribution of the propriate of the contribution of the propriate of the contribution of the co

The major contributions of this work are a simple and powerful interface that enables automatic parallelization and distribution of large-scale computations, combined with an implementation of this interface that achieves high performance on large clusters of commodity PCs.

Section 2 describes the basic programming model and gives several examples. Section 3 describes an implementation of the MapReduce interface tailored towards our cluster based computing environment. Section 4 describes several refinements of the programming model that we have found useful. Section 5 has performance measurements of our implementation for a variety of tasks. Section 6 explores the use of MapReduce within Goods including our exteriences in useful task that the

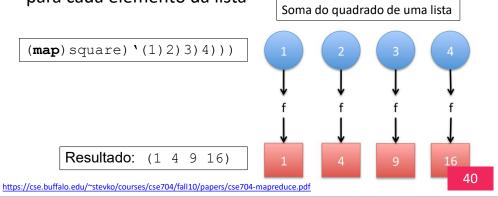
To appear in OSDI 2004

 $\underline{https://static.googleusercontent.com/media/research.google.com/en//archive/mapreduce-osdi04.pdf}$

FIAP

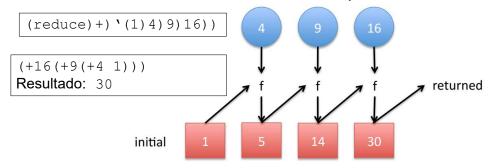
Map e Reduce no Lisp

- Lisp é uma linguagem funcional, projetada por John McCarthy que apareceu pela primeira vez em 1958.
- A primitiva map recebe como parâmetros um operador unário e uma lista, onde este operador será chamada para cada elemento da lista



Map e Reduce no Lisp

 A primitiva reduce recebe como parâmetros um operador binário e uma lista, onde os elementos da lista serão combinados utilizando este operador



https://cse.buffalo.edu/~stevko/courses/cse704/fall10/papers/cse704-mapreduce.pdf

Map Reduce em Lisp

- Map
 - processa cada registro individualmente
- Reduce
 - Processa (combina) o conjunto de todos os registros em lote

ttps://cse.buffalo.edu/~stevko/courses/cse704/fall10/papers/cse704-mapreduce.pdf

O que a Google percebeu

• Pesquisa por palavra-chave

Map

Reduce

- Encontre uma palavra-chave em cada página da web individualmente
 e, se ela for encontrada, retorne sua URL
- Combine todos os resultados (URLs) e devolva-os
 - Contagem do número de ocorrências de cada palavra
 - Conte o número de ocorrências em cada página da web individualmente e retorne a lista de <palavra, número>

Para cada palavra, some (combine) a contagem

https://renil.wordpress.com/2007/05/03/mapreduce-functional-programming-lisp/

Visão Geral do Map Reduce

Мар

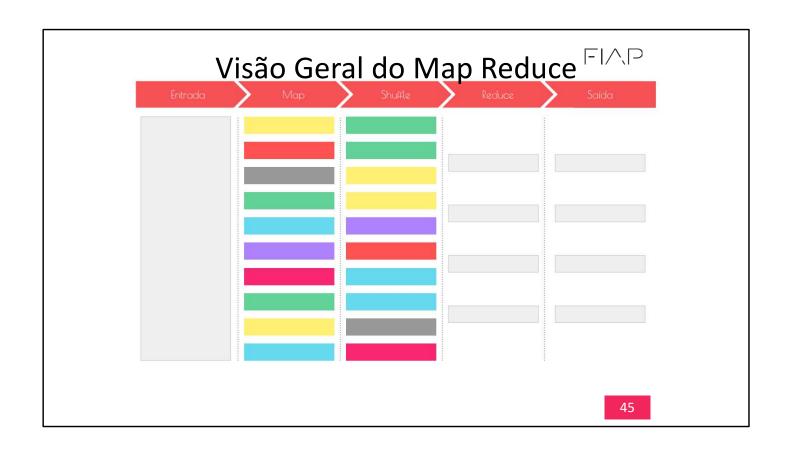
Os dados na fase map são divididos entre os nós task tracker onde os dados estão localizados. Cada nó na fase map emite pares chave-valor com base no registro de entrada, um registro por vez.

Shuffle

A fase shuffle é tratada pela estrutura Hadoop. Ela transfere os resultados dos mappers para os reducers juntando os resultados por meio chave.

Reduce

A saída dos mappers é enviado para os reducers. Os dados na fase reduce são divididos em partições onde cada reducer lê uma chave e uma lista de valores associados a essa chave. Os reducers emitem zero ou mais pares chavevalor com base na lógica utilizada



Visão Geral do Map Reduce FIAP bela bela bela 1.1 bela belo jovem bela 1, 1, 1 belo belo cidade α A bela jovem saiu belo com com com belo desta com um belo rapaz belo cidade jovem jovem rapaz com desta para para para passeio no belo jovem parque parque parque desta bela belo passeio passeio passeio para rapaz rapaz " cidade belo passeio um 1.1 um

rapaz

saiu

um

parque

desta

bela cidade

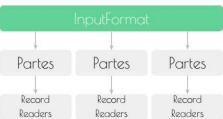
FIAP

InputFormat

- O primeiro passo para executar um programa MapReduce é localizar e ler o arquivo de entrada contendo os dados brutos.
- O formato do arquivo é completamente arbitrário, mas os dados devem ser convertidos para algo que o programa pode processar.
- Isso é feito pelo InputFormat e RecordReader.
- InputFormat decide como o arquivo será dividido em peças menores para processamento usando uma função chamada InputSplit.

InputFormat

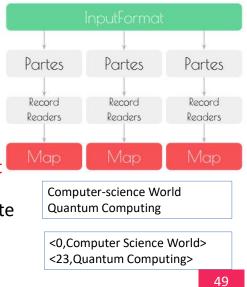
 O objeto InputFormat é responsável por validar a entrada, dividindo os arquivos entre os mappers e instanciando os objetos RecordReaders.



- Por padrão, o tamanho de uma parte é igual ao tamanho de um bloco que no Hadoop o padrão é 64 Mb.
- As partes possuem um conjunto de registros onde cada um deles será quebrado em pares chave-valor para o map. A separação dos registros é feita antes mesmo da instanciação do processo map.
- O job que está executando a tarefa MapReduce tentará colocar a tarefa map o mais próximo dos dados possível, ou seja, executar o processo map no mesmo nó do cluster onde o dados está armazenado.

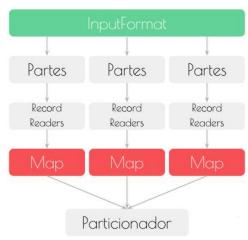
Método MAP

- O método map recebe como argumento 3 parâmetros:
 - Writable chave,
 - Writable valor e
 - context.
- Por padrão, o RecordReader define a chave para o método map como sendo o byte offset do registro no arquivo de entrada e o valor é basicamente a linha inteira.



Particionador

- O particionador recebe a saída gerada pelo método map e faz um hash da chave e cria uma partição com base no hash da chave.
- Cada partição se destina a um reducer, assim, todos os registros com a mesma chave serão enviados para a mesmo partição (e, portanto, enviados para o mesmo reducer).



Reduce

- O método reduce é chamado para cada chave e a lista de valores associados a essa chave.
- O método reduce processa cada valor e grava o envia o resultado para o contexto.
- O **OutputCommitter** cria um arquivo de saída para cada reduce executado.



OutputFormat

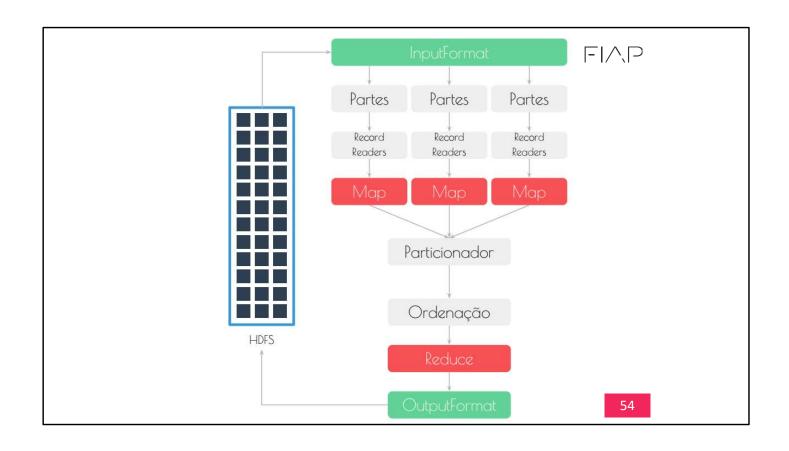
- Os resultados de um job MapReduce são armazenados no diretório especificado pelo usuário.
- Um arquivo vazio chamado _SUCCESS é criado para indicar que o job foi concluído com sucesso (mas não necessariamente sem erros).

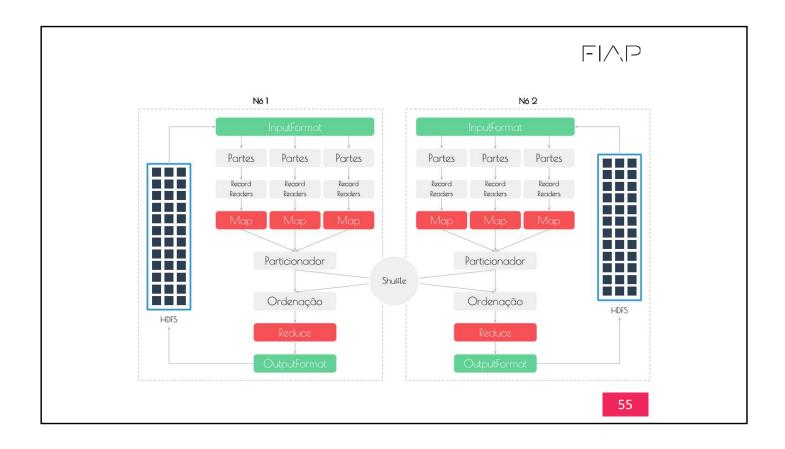


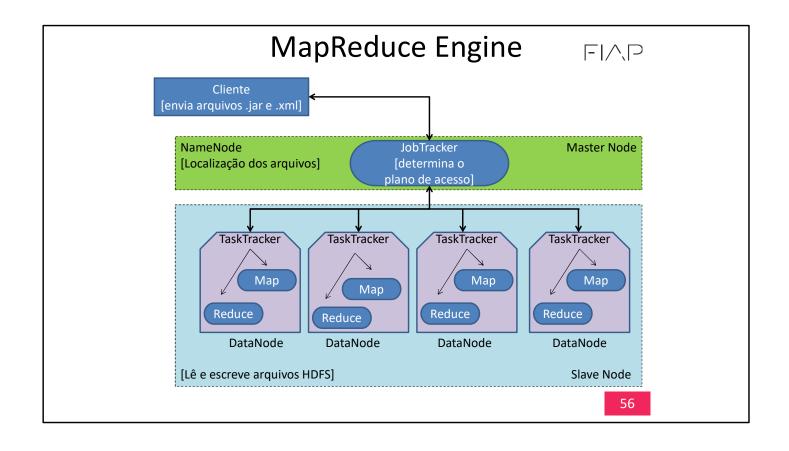
OutputFormat

- O histórico do job é armazenado em _logs/history*.
- A saída do método reduce é salvo em arquivos denominados part-r-00000, part-r-00001, ... (um para cada reduce).
- Caso seja executada uma tarefa apenas de mapeamento, implementação apenas do map, os nomes dos arquivos de saída serão part-m-00000, part-m-00001, ... etc.









FIAP

Exemplo: Contador de Palavras

• Incluindo as palavras dog, cat, mouse e hippo em um banco orientado a documentos.

```
db.items.insert({tags: ['dog', 'cat']})
db.items.insert({tags: ['dog']})
db.items.insert({tags: ['dog', 'mouse']})
db.items.insert({tags: ['dog', 'mouse', 'hippo']})
db.items.insert({tags: ['dog', 'mouse', 'hippo']})
db.items.insert({tags: ['dog', 'hippo']})
```

Fonte: https://docs.mongodb.org/manual/tutorial/map-reduce-Exemplos/

Exemplo: Contador de Palavras

• Criando o mapeamento

```
var map = function() {
  this.tags.forEach(function(t) {
    emit(t, {count: 1});
  });
}
```

Fonte: https://docs.mongodb.org/manual/tutorial/map-reduce-Exemplos/

Exemplo: Contador de Palavras

• Criando o reduce

```
var reduce = function(key, values) {
  var count = 0;
  for(var i=0, len=values.length; i<len; i++) {
    count += values[i].count;
  }
  return {count: count};
}</pre>
```

Fonte: https://docs.mongodb.org/manual/tutorial/map-reduce-Exemplos/

Exemplo: Contador de Palavras

• Executando o MapReduce

Fonte: https://docs.mongodb.org/manual/tutorial/map-reduce-Exemplos/

Exemplo: Contador de Palavras

• Executando o MapReduce

Fonte: https://docs.mongodb.org/manual/tutorial/map-reduce-Exemplos/

 $FI \land P$

Submetendo um job MapReduce

- WordCount.java
 - Classe de drive do MapReduce para executar o job
- WordMapper.java
 - Uma classe mapper para emitir para emitir palavras
- SumReducer.java
 - Uma classe reducer para contar palavras

https://www.dropbox.com/sh/bsopakcxg7wctfu/AAA-r0 LQkT0ze54KnzYzhDMa?dl=0